

Documentación Completa de Features

Pipeline ML para Predicción de Vacancias en Nanoestructuras

1. Features de Mean Shift Clustering

1.1 Features Básicas

`ms_n_clusters`

Descripción: Número total de clusters identificados en la estructura atómica.

Ecuación:

$$n_clusters = |\text{unique}(\text{labels})|$$

Interpretación: Indica cuántas regiones de alta densidad atómica existen. Valores altos sugieren fragmentación espacial.

`ms_bandwidth`

Descripción: Parámetro de ancho de banda usado para el clustering, representa la escala de búsqueda de densidad.

Ecuación:

$$\text{bandwidth} = \text{estimate_bandwidth}(\text{points}, \text{quantile})$$

o en caso de fallo:

$$\text{bandwidth} = 2 \times \text{mean}(\text{dist_nearest_neighbor})$$

Interpretación: Define el radio de influencia para determinar vecindarios densos.

`ms_largest_cluster_size`

Descripción: Número de átomos en el cluster más grande.

Ecuación:

$$\text{max}(\text{cluster_sizes})$$

Interpretación: Mide la concentración máxima de átomos en una región.

ms_avg_cluster_size

Descripción: Tamaño promedio de los clusters.

Ecuación:

$$\mu_{\text{size}} = (1/n_{\text{clusters}}) \sum \text{size}_i$$

Interpretación: Caracteriza el tamaño típico de agrupaciones atómicas.

ms_cluster_size_std

Descripción: Desviación estándar de los tamaños de clusters.

Ecuación:

$$\sigma_{\text{size}} = \sqrt{[(1/n) \sum (\text{size}_i - \mu_{\text{size}})^2]}$$

Interpretación: Mide la heterogeneidad en tamaños de clusters. Valores altos indican distribución irregular.

1.2 Features de Proporción

ms_largest_cluster_ratio

Descripción: Fracción de átomos contenidos en el cluster más grande.

Ecuación:

$$\text{ratio} = \text{largest_cluster_size} / N_{\text{total}}$$

Interpretación: Indica qué tan dominante es la región más densa.

ms_smallest_cluster_ratio

Descripción: Fracción de átomos en el cluster más pequeño.

Ecuación:

$$\text{ratio} = \min(\text{cluster_sizes}) / N_{\text{total}}$$

Interpretación: Caracteriza la escala de las agrupaciones mínimas.

1.3 Features de Separación Espacial

ms_avg_centroid_distance

Descripción: Distancia promedio entre centroides de clusters.

Ecuación:

$$d_{avg} = (2/(n(n-1))) \sum_i \sum_j ||c_i - c_j|| \quad \text{para } i < j$$

Interpretación: Mide la separación típica entre regiones densas.

ms_min_centroid_distance

Descripción: Distancia mínima entre cualquier par de centroides.

Ecuación:

$$d_{min} = \min(||c_i - c_j||) \quad \text{para } i \neq j$$

Interpretación: Identifica los clusters más cercanos entre sí.

ms_cluster_size_cv

Descripción: Coeficiente de variación de tamaños de clusters.

Ecuación:

$$CV = \sigma_{size} / \mu_{size}$$

Interpretación: Medida normalizada de heterogeneidad. $CV < 1$ indica uniformidad, $CV > 1$ indica alta variabilidad.

1.4 Features de Dispersión Espacial

ms_avg_cluster_spread

Descripción: Dispersión promedio de átomos dentro de cada cluster respecto a su centroide.

Ecuación:

$$\text{spread}_k = (1/|C_k|) \sum_{i \in C_k} \|r_i - c_k\|$$

$$\text{spread_avg} = (1/n_clusters) \sum_k \text{spread}_k$$

Interpretación: Mide qué tan compactos son los clusters en promedio.

ms_max_cluster_spread

Descripción: Máxima dispersión observada en cualquier cluster.

Ecuación:

$$\text{spread_max} = \max_k(\text{spread}_k)$$

Interpretación: Identifica el cluster menos compacto.

2. Momentos de Inercia

2.1 Tensor de Inercia

moi_lxx, **moi_lyy**, **moi_lzz**

Descripción: Momentos principales de inercia respecto a los ejes cartesianos.

Ecuaciones:

$$I_{xx} = \sum_i (y_i^2 + z_i^2)$$

$$I_{yy} = \sum_i (x_i^2 + z_i^2)$$

$$I_{zz} = \sum_i (x_i^2 + y_i^2)$$

Interpretación: Cuantifican la distribución de masa respecto a cada eje. Valores altos indican masa alejada del eje.

moi_lxy, **moi_lxz**, **moi_lyz**

Descripción: Productos de inercia (términos cruzados del tensor).

Ecuaciones:

$$I_{xy} = -\sum_i (x_i \cdot y_i)$$

$$I_{xz} = -\sum_i (x_i \cdot z_i)$$

$$I_{yz} = -\sum_i (y_i \cdot z_i)$$

Interpretación: Miden el acoplamiento entre ejes. Valores cercanos a cero indican ejes principales alineados con coordenadas.

2.2 Valores Propios

$moi_principal_1$, $moi_principal_2$, $moi_principal_3$

Descripción: Momentos principales de inercia (eigenvalores del tensor), ordenados $\lambda_1 \geq \lambda_2 \geq \lambda_3$.

Ecuación:

$$I_tensor = \begin{bmatrix} I_{xx} & I_{xy} & I_{xz} \\ I_{xy} & I_{yy} & I_{yz} \\ I_{xz} & I_{yz} & I_{zz} \end{bmatrix}$$

$$\lambda_1, \lambda_2, \lambda_3 = \text{eigenvalues}(I_tensor)$$

Interpretación: Describen la distribución de masa en los ejes principales (independientes de orientación).

2.3 Medidas de Forma

$moi_anisotropy$

Descripción: Anisotropía del sistema, mide qué tan alejado está de una distribución esférica.

Ecuación:

$$A = (\lambda_1 - \lambda_3) / \lambda_1$$

Interpretación: $A = 0$ para esfera perfecta, $A \rightarrow 1$ para estructuras altamente anisotrópicas.

$moi_sphericity$

Descripción: Esfericidad basada en momentos de inercia.

Ecuación:

$$S = \lambda_3 / \lambda_1$$

Interpretación: $S = 1$ para esfera, $S < 1$ para formas elongadas o aplanadas.

moi_aspect_ratio

Descripción: Relación de aspecto entre los dos momentos principales más grandes.

Ecuación:

$$AR = \lambda_1 / \lambda_2$$

Interpretación: $AR \approx 1$ indica simetría en el plano principal, $AR \gg 1$ indica elongación.

3. Distribución Radial (RDF)

3.1 Histograma

rdf_bin_i ($i = 0, 1, \dots, 19$)

Descripción: Fracción de átomos en el bin radial i .

Ecuación:

$$r_i = ||\vec{r}_i - \vec{r}_{cm}||$$

$$rdf_bin_k = n_k / N_{total}$$

$$\text{donde } n_k = |\{i : r_{min} + k \cdot \Delta r \leq r_i < r_{min} + (k+1) \cdot \Delta r\}|$$

Interpretación: Describe la distribución de densidad en función de la distancia al centro de masa.

3.2 Estadísticas

rdf_mean

Descripción: Distancia radial promedio desde el centro de masa.

Ecuación:

$$\bar{r} = (1/N) \sum_i ||\vec{r}_i - \vec{r}_{cm}||$$

Interpretación: Radio efectivo promedio de la estructura.

rdf_std

Descripción: Desviación estándar de las distancias radiales.

Ecuación:

$$\sigma_r = \sqrt{[(1/N) \sum_i (r_i - \bar{r})^2]}$$

Interpretación: Mide la dispersión radial. Valores altos indican distribución amplia.

rdf_skewness

Descripción: Asimetría de la distribución radial.

Ecuación:

$$\gamma_1 = E[(r - \mu)^3] / \sigma^3 = (1/N) \sum_i [(r_i - \bar{r}) / \sigma_r]^3$$

Interpretación: $\gamma_1 > 0$: cola hacia radios grandes; $\gamma_1 < 0$: cola hacia radios pequeños; $\gamma_1 = 0$: simétrica.

rdf_kurtosis

Descripción: Curtosis de la distribución radial (exceso de curtosis).

Ecuación:

$$\gamma_2 = E[(r - \mu)^4] / \sigma^4 - 3$$

Interpretación: $\gamma_2 > 0$: colas pesadas (más outliers); $\gamma_2 < 0$: colas ligeras; $\gamma_2 = 0$: normal.

rdf_entropy

Descripción: Entropía de Shannon de la distribución radial.

Ecuación:

$$H = -\sum_k p_k \log(p_k)$$

donde $p_k = \text{rdf_bin}_k$

Interpretación: Mide el desorden de la distribución radial. H alta indica distribución uniforme.

3.3 Percentiles

`rdf_percentile_p` ($p = 25, 50, 75, 90, 95$)

Descripción: Percentiles de la distribución de distancias radiales.

Ecuación:

$$P_p = \inf\{x : F(x) \geq p/100\}$$

donde $F(x) = |\{i : r_i \leq x\}| / N$

Interpretación: Caracterizan la forma de la distribución. p50 es la mediana.

4. Conectividad

`connectivity_clusters`

Descripción: Número de componentes conectados en el grafo de proximidad.

Ecuación:

Grafo $G = (V, E)$

$$E = \{(i,j) : ||\vec{r}_i - \vec{r}_j|| < \text{threshold}\}$$

$n_{\text{components}}$ = número de componentes conexos en G

Interpretación: Cuantifica fragmentación espacial. Valores altos indican estructura discontinua.

`connectivity_largest_cluster`

Descripción: Tamaño del componente conectado más grande.

Ecuación:

$$\max(|C_k|) \text{ para todos los componentes } C_k$$

Interpretación: Mide la región continua más grande.

connectivity_avg_cluster_size

Descripción: Tamaño promedio de componentes conectados.

Ecuación:

$$\mu_{\text{comp}} = (1/n_{\text{components}}) \sum_k |C_k|$$

Interpretación: Caracteriza el tamaño típico de regiones conectadas.

connectivity_isolation

Descripción: Fracción de átomos aislados (sin vecinos dentro del threshold).

Ecuación:

$$\text{isolation} = |\{i : \text{degree}(i) = 0\}| / N$$

Interpretación: Cuantifica átomos desconectados. Puede indicar defectos superficiales.

connectivity_avg_degree

Descripción: Grado promedio en el grafo de proximidad.

Ecuación:

$$\bar{k} = (1/N) \sum_i \text{degree}(i)$$

$$\text{donde } \text{degree}(i) = |\{j : ||\vec{r}_i - \vec{r}_j|| < \text{threshold}\}|$$

Interpretación: Número promedio de vecinos cercanos por átomo.

connectivity_clustering_coeff

Descripción: Coeficiente de clustering local promedio.

Ecuación:

$$C_i = 2E_i / [k_i(k_i - 1)]$$

donde E_i = número de aristas entre vecinos de i

k_i = degree(i)

$$C = (1/N) \sum_i C_i$$

Interpretación: Mide qué tan interconectados están los vecinos de cada átomo. C alto indica estructura compacta.

5. Curvatura de Superficie

curvature_mean

Descripción: Curvatura promedio de la superficie (aproximada).

Ecuación:

Para cada vértice v del convex hull:

- Ajustar plano a vecinos usando SVD
- $U, \Sigma, V^T = \text{SVD}(\text{puntos_vecinos_centrados})$

$$\kappa_v \approx \sigma_3 / \sigma_2$$

$$\kappa_{\text{mean}} = (1/n_{\text{vertices}}) \sum_v \kappa_v$$

Interpretación: Cuantifica la curvatura típica. Valores altos indican superficie irregular.

curvature_std

Descripción: Desviación estándar de la curvatura.

Ecuación:

$$\sigma_{\kappa} = \sqrt{(1/n) \sum_v (\kappa_v - \kappa_{\text{mean}})^2}$$

Interpretación: Mide variabilidad de curvatura. Alto indica heterogeneidad superficial.

curvature_max, **curvature_min**

Descripción: Curvaturas máxima y mínima observadas.

Ecuación:

$$\kappa_{\max} = \max_v(\kappa_v)$$

$$\kappa_{\min} = \min_v(\kappa_v)$$

Interpretación: Identifican regiones de máxima/mínima curvatura.

6. Features Topológicas

6.1 Gradiente de Energía

`topo_energy_gradient_mean`

Descripción: Gradiente espacial promedio de energía potencial.

Ecuación:

$$\nabla E_{ij} = |E_i - E_j| / ||\vec{r}_i - \vec{r}_j||$$

$$\nabla E_{\text{mean}} = \text{mean}(\nabla E_{ij}) \text{ para todos los pares } (i,j)$$

Interpretación: Mide qué tan rápido cambia la energía en el espacio. Alto indica inhomogeneidad energética.

`topo_energy_gradient_std`, `topo_energy_gradient_max`

Descripción: Desviación estándar y máximo del gradiente de energía.

Ecuación:

$$\sigma_{\nabla E} = \text{std}(\nabla E_{ij})$$

$$\nabla E_{\max} = \max(\nabla E_{ij})$$

Interpretación: Caracterizan la variabilidad del gradiente energético.

`topo_energy_heterogeneity`

Descripción: Heterogeneidad relativa de la energía.

Ecuación:

$$H_E = \sigma_E / |\mu_E|$$

Interpretación: Coeficiente de variación energético. Normalizado por la magnitud promedio.

6.2 Dimensión Fractal

`topo_fractal_dimension`

Descripción: Dimensión fractal estimada por box-counting.

Ecuación:

Para diferentes tamaños de caja ϵ :

$N(\epsilon)$ = número de cajas ocupadas

$$D = \lim_{\epsilon \rightarrow 0} [\log N(\epsilon) / \log(1/\epsilon)]$$

Aproximado por regresión lineal: $\log N$ vs $\log(1/\epsilon)$

Interpretación: $D \approx 2$ para superficie plana, $D > 2$ para superficie rugosa. Cuantifica complejidad geométrica.

7. Análisis de Capas

`layers_count`

Descripción: Número de capas radiales detectadas mediante análisis de picos.

Ecuación:

$h(r)$ = histograma de distancias radiales

`peaks = find_peaks(h, prominence > threshold)`

`layers_count = |peaks|`

Interpretación: Identifica estructura de capas concéntricas. Común en nanopartículas.

`layers_avg_spacing`

Descripción: Espaciado promedio entre capas consecutivas.

Ecuación:

r_k = posición radial del pico k

$$\Delta r_k = r_{\{k+1\}} - r_k$$

$$\text{spacing_avg} = (1/(n-1)) \sum_k \Delta r_k$$

Interpretación: Mide la periodicidad radial. Relacionado con parámetros de red.

layers_spacing_std

Descripción: Desviación estándar del espaciado entre capas.

Ecuación:

$$\sigma_{\Delta r} = \sqrt{[(1/(n-1)) \sum_k (\Delta r_k - \text{spacing_avg})^2]}$$

Interpretación: Cuantifica regularidad del espaciado.

layers_regularity

Descripción: Medida de regularidad de las capas.

Ecuación:

$$R = 1 - (\sigma_{\Delta r} / \text{spacing_avg})$$

Interpretación: $R \rightarrow 1$ indica capas muy regulares, $R \rightarrow 0$ indica irregularidad.

layers_population_variance

Descripción: Varianza en el número de átomos por capa.

Ecuación:

pop_k = población del pico k

$$\text{var_pop} = (1/n) \sum_k (\text{pop}_k - \mu_{\text{pop}})^2$$

Interpretación: Mide uniformidad de población entre capas.

layers_outer_inner_ratio

Descripción: Relación entre población de capa externa e interna.

Ecuación:

$$\text{ratio} = \text{pop_outer} / \text{pop_inner}$$

Interpretación: Caracteriza diferencia entre superficie y núcleo.

8. Entropía Espacial

entropy_spatial

Descripción: Entropía de Shannon en grid 3D.

Ecuación:

Dividir espacio en grid 3D de n^3 celdas

$p_k = n_k / N$ (fracción de átomos en celda k)

$$H = -\sum_k p_k \log(p_k) \quad \text{para } p_k > 0$$

Interpretación: Mide desorden espacial. H alta indica distribución uniforme.

entropy_spatial_normalized

Descripción: Entropía normalizada por el máximo teórico.

Ecuación:

$$H_{\text{norm}} = H / \log(n_{\text{bins_occupied}})$$

Interpretación: Valor en $[0,1]$. $H_{\text{norm}} = 1$ para distribución perfectamente uniforme.

spatial_uniformity

Descripción: Uniformidad de distribución espacial.

Ecuación:

$$U = 1 / (1 + \text{var}(\text{occupancy}))$$

Interpretación: $U \rightarrow 1$ indica ocupación uniforme de celdas.

spatial_concentration

Descripción: Concentración espacial relativa.

Ecuación:

$$C = \max(\text{occupancy}) / \text{mean}(\text{occupancy})$$

Interpretación: $C \approx 1$ indica uniformidad, $C \gg 1$ indica regiones muy concentradas.

9. Convex Hull

9.1 Propiedades Básicas

convex_hull_volume

Descripción: Volumen del convex hull (envoltura convexa).

Ecuación:

$$V = \text{volumen calculado por algoritmo QHull}$$

Interpretación: Volumen mínimo que contiene todos los átomos. Aproxima volumen total de la estructura.

convex_hull_surface_area

Descripción: Área superficial del convex hull.

Ecuación:

$$A = \sum_k \text{área}(\text{face}_k)$$

Interpretación: Área de la superficie externa. Relacionada con energía superficial.

convex_hull_n_vertices

Descripción: Número de vértices del convex hull.

Ecuación:

$$n_v = |\text{vertices}|$$

Interpretación: Cuantifica complejidad de la forma. Más vértices indica forma menos suave.

$$\text{convex_hull_n_faces}$$

Descripción: Número de caras del convex hull.

Ecuación:

$$n_f = |\text{simplices}|$$

Interpretación: Relacionado con complejidad geométrica por relación de Euler.

9.2 Propiedades Derivadas

$$\text{hull_compactness}$$

Descripción: Compacidad isoperimétrica.

Ecuación:

$$C = 36\pi V^2 / A^3$$

Interpretación: $C = 1$ para esfera perfecta, $C < 1$ para otras formas. Mide qué tan compacta es la forma.

$$\text{sphericity_wadell}$$

Descripción: Esfericidad de Wadell.

Ecuación:

$$r_{\text{equiv}} = (3V / 4\pi)^{1/3}$$

$$A_{\text{sphere}} = 4\pi r_{\text{equiv}}^2$$

$$S = A_{\text{sphere}} / A_{\text{hull}}$$

Interpretación: $S = 1$ para esfera, $S < 1$ para formas menos esféricas.

$$\text{elongation}$$

Descripción: Elongación basada en momentos de inercia.

Ecuación:

$$E = \sqrt{I_1 / I_3}$$

Interpretación: $E = 1$ para forma isotrópica, $E > 1$ para formas elongadas.

planarity

Descripción: Planaridad de la estructura.

Ecuación:

$$P = (I_2 - I_3) / I_2 \quad \text{si } I_2 > 0$$

Interpretación: $P \rightarrow 1$ indica estructura plana, $P \rightarrow 0$ indica estructura 3D.

10. Bounding Box

bbox_volume

Descripción: Volumen del bounding box alineado con ejes.

Ecuación:

$$V_{\text{box}} = \Delta x \cdot \Delta y \cdot \Delta z$$

donde $\Delta x = x_{\text{max}} - x_{\text{min}}$, etc.

Interpretación: Límite superior del volumen ocupado.

bbox_surface_area

Descripción: Área superficial del bounding box.

Ecuación:

$$A_{\text{box}} = 2(\Delta x \cdot \Delta y + \Delta x \cdot \Delta z + \Delta y \cdot \Delta z)$$

Interpretación: Área de la caja que contiene la estructura.

bbox_dim_x,

bbox_dim_y,

bbox_dim_z

Descripción: Dimensiones del bounding box en cada eje.

Ecuación:

$$\Delta x = x_{\text{max}} - x_{\text{min}}$$

$$\Delta y = y_{\text{max}} - y_{\text{min}}$$

$$\Delta z = z_{\text{max}} - z_{\text{min}}$$

Interpretación: Extensión espacial en cada dirección.

`aspect_ratio_xy`, `aspect_ratio_xz`, `aspect_ratio_yz`

Descripción: Relaciones de aspecto entre dimensiones.

Ecuación:

$$AR_{xy} = \Delta x / \Delta y$$

$$AR_{xz} = \Delta x / \Delta z$$

$$AR_{yz} = \Delta y / \Delta z$$

Interpretación: $AR \approx 1$ indica simetría entre ejes, $AR \gg 1$ indica elongación preferencial.

11. Centroide y Radio

`centroid_x`, `centroid_y`, `centroid_z`

Descripción: Coordenadas del centro de masa.

Ecuación:

$$\vec{r}_{\text{cm}} = (1/N) \sum_i \vec{r}_i = (\bar{x}, \bar{y}, \bar{z})$$

Interpretación: Posición promedio de los átomos. Centro geométrico de la estructura.

`effective_radius`

Descripción: Radio efectivo promedio.

Ecuación:

$$R_{\text{eff}} = (1/N) \sum_i ||\vec{r}_i - \vec{r}_{\text{cm}}||$$

Interpretación: Radio promedio de la distribución atómica.

radius_std

Descripción: Desviación estándar del radio.

Ecuación:

$$\sigma_R = \sqrt{\left[\frac{1}{N} \sum_i (||\vec{r}_i - \vec{r}_{cm}|| - R_{eff})^2 \right]}$$

Interpretación: Mide dispersión radial de átomos.

max_distance_from_centroid

Descripción: Distancia máxima de cualquier átomo al centro de masa.

Ecuación:

$$R_{max} = \max_i (||\vec{r}_i - \vec{r}_{cm}||)$$

Interpretación: Radio máximo de la estructura.

12. Ratios Derivados

volume_ratio_hull_to_bbox

Descripción: Relación entre volumen del hull y bounding box.

Ecuación:

$$R_V = V_{hull} / V_{bbox}$$

Interpretación: $R_V \rightarrow 1$ indica estructura rectangular, $R_V \ll 1$ indica estructura irregular con mucho espacio vacío.

surface_ratio_hull_to_bbox

Descripción: Relación entre áreas del hull y bounding box.

Ecuación:

$$R_A = A_hull / A_bbox$$

Interpretación: Cuantifica rugosidad relativa de la superficie.

atom_density_in_hull

Descripción: Densidad atómica dentro del convex hull.

Ecuación:

$$\rho = N / V_hull$$

Interpretación: Número de átomos por unidad de volumen. Indica compactación.

13. Features Atómicas Agregadas

Para cada propiedad atómica **prop** (pe, stress_vm, coord, sxx, syy, szz, sxy, sxz, syz, voro_vol, ke):

13.1 Estadísticos de Orden

prop_min, **prop_max**

Descripción: Valores mínimo y máximo de la propiedad.

Ecuación:

$$\min(prop), \max(prop)$$

prop_p10, **prop_p25**, **prop_median**, **prop_p75**, **prop_p90**

Descripción: Percentiles de la distribución.

Ecuación:

$$P_q = \inf\{x : F(x) \geq q\}$$

13.2 Momentos Estadísticos

prop_mean

Descripción: Valor promedio de la propiedad.

Ecuación:

$$\mu = (1/N) \sum_i \text{prop}_i$$

prop_std

Descripción: Desviación estándar.

Ecuación:

$$\sigma = \sqrt{[(1/(N-1)) \sum_i (\text{prop}_i - \mu)^2]}$$

prop_skew

Descripción: Asimetría (skewness).

Ecuación:

$$\gamma_1 = (1/N) \sum_i [(\text{prop}_i - \mu)/\sigma]^3$$

Interpretación: $\gamma_1 > 0$: cola derecha; $\gamma_1 < 0$: cola izquierda; $\gamma_1 = 0$: simétrica.

prop_kurt

Descripción: Curtosis (kurtosis, exceso).

Ecuación:

$$\gamma_2 = (1/N) \sum_i [(\text{prop}_i - \mu)/\sigma]^4 - 3$$

Interpretación: $\gamma_2 > 0$: colas pesadas; $\gamma_2 < 0$: colas ligeras.

14. Histogramas Específicos

14.1 Coordinación

coord_bin_4_5, **coord_bin_6_7**, **coord_bin_8_9**, **coord_bin_10_11**, **coord_bin_12**

Descripción: Fracción de átomos con coordinación en rangos específicos.

Ecuación:

$$\text{coord_bin_a_b} = |\{i : a \leq \text{coord_i} \leq b\}| / N$$

Interpretación: Caracteriza entorno local. coord_bin_12 indica átomos en red FCC/HCP perfecta.

coord_below_8

Descripción: Fracción de átomos sub-coordinados.

Ecuación:

$$= |\{i : \text{coord_i} < 8\}| / N$$

Interpretación: Indica átomos en superficie o cerca de defectos.

coord_perfect_12

Descripción: Fracción de átomos con coordinación perfecta.

Ecuación:

$$= |\{i : \text{coord_i} = 12\}| / N$$

Interpretación: Mide perfección cristalina local.

14.2 Energía Potencial

pe_bin_i (i = 0, 1, ..., 9)

Descripción: Fracción de átomos con energía potencial en el bin i.

Ecuación:

$$\begin{aligned} E_{\min} &= -4.5, E_{\max} = -4.0 \\ \text{bins} &= \text{linspace}(E_{\min}, E_{\max}, 11) \\ \text{pe_bin_k} &= |\{i : \text{bins}[k] \leq E_i < \text{bins}[k+1]\}| / N \end{aligned}$$

Interpretación: Caracteriza distribución energética. Bins de baja energía indican átomos en posiciones estables.

pe_below_min

Descripción: Fracción de átomos con energía menor al mínimo del rango.

Ecuación:

$$= |\{i : E_i < E_{\min}\}| / N$$

Interpretación: Átomos con energía excepcionalmente baja (muy estables).

pe_above_max

Descripción: Fracción de átomos con energía mayor al máximo del rango.

Ecuación:

$$= |\{i : E_i > E_{\max}\}| / N$$

Interpretación: Átomos con energía alta (potencialmente inestables o en defectos).

pe_absolute_min

Descripción: Energía potencial mínima absoluta en el sistema.

Ecuación:

$$E_{\min_abs} = \min_i(E_i)$$

Interpretación: Identifica el átomo más estable energéticamente.

15. Indicadores de Defectos Bulk

15.1 Coordinación

frac_coord_le_11, **frac_coord_le_10**, **frac_coord_le_9**

Descripción: Fracción de átomos con coordinación ≤ 11 , ≤ 10 , ≤ 9 .

Ecuación:

$$\text{frac_coord_le_n} = |\{i : \text{coord}_i \leq n\}| / N$$

Interpretación: Indicadores de defectos. En FCC perfecto, todos tienen coord=12. Valores altos indican muchos defectos o superficie.

15.2 Segunda Capa de Coordinación

`frac_coord2_le_5`, `frac_coord2_le_4`, `frac_coord2_le_3`

Descripción: Fracción de átomos con segunda coordinación baja.

Ecuación:

$$\text{frac_coord2_le_n} = |\{i : \text{coord2_i} \leq n\}| / N$$

Interpretación: Segunda capa de vecinos. Baja coordinación secundaria indica proximidad a superficie o vacancia.

15.3 Estrés de von Mises

`frac_vm_top5`

Descripción: Fracción de átomos en el top 5% de estrés de von Mises.

Ecuación:

$$\text{threshold} = \text{percentile_95}(\text{stress_vm})$$

$$\text{frac} = |\{i : \text{stress_vm_i} \geq \text{threshold}\}| / N$$

Interpretación: Identifica átomos bajo alto estrés mecánico. Relacionado con defectos y concentradores de estrés.

15.4 Energía Potencial

`frac_pe_top5`

Descripción: Fracción de átomos en el top 5% de energía potencial.

Ecuación:

$$\text{threshold} = \text{percentile_95}(\text{pe})$$

$$\text{frac} = |\{i : \text{pe_i} \geq \text{threshold}\}| / N$$

Interpretación: Átomos energéticamente inestables. Posibles sitios de defectos.

16. Estrés de von Mises

`stress_vm` (agregados)

Descripción: Estrés de von Mises calculado a partir del tensor de estrés.

Ecuación:

$$\bar{\sigma} = (\sigma_{xx} + \sigma_{yy} + \sigma_{zz}) / 3$$

$$\sigma'_{xx} = \sigma_{xx} - \bar{\sigma}$$

$$\sigma'_{yy} = \sigma_{yy} - \bar{\sigma}$$

$$\sigma'_{zz} = \sigma_{zz} - \bar{\sigma}$$

$$\sigma_{vm} = \sqrt{[3/2 (\sigma'_{xx}^2 + \sigma'_{yy}^2 + \sigma'_{zz}^2 + 2\sigma_{xy}^2 + 2\sigma_{xz}^2 + 2\sigma_{yz}^2)]}$$

Interpretación: Estrés equivalente escalar. Útil para criterio de falla de von Mises. Alto indica estrés multiaxial significativo.

17. Invariante de Estrés I_1

stress_l1 (agregados)

Descripción: Primer invariante del tensor de estrés (traza).

Ecuación:

$$I_1 = \sigma_{xx} + \sigma_{yy} + \sigma_{zz} = \text{tr}(\sigma)$$

Interpretación: Mide estrés hidrostático. $I_1 > 0$: tensión, $I_1 < 0$: compresión, $I_1 = 0$: estrés puramente desviatorio.

18. Componentes de Estrés

sxx, **syy**, **szz** (agregados)

Descripción: Componentes normales del tensor de estrés.

Ecuación:

$$\sigma_{xx}, \sigma_{yy}, \sigma_{zz} \text{ (directamente de simulación)}$$

Interpretación: Estrés en dirección de cada eje. Positivo = tensión, negativo = compresión.

sxy, **sxz**, **syz** (agregados)

Descripción: Componentes de corte del tensor de estrés.

Ecuación:

σ_{xy} , σ_{xz} , σ_{yz} (directamente de simulación)

Interpretación: Estrés de corte en planos respectivos. Relacionado con deformación angular.

19. Volumen de Voronoi

voro_vol (agregados)

Descripción: Volumen de la celda de Voronoi de cada átomo.

Ecuación:

$V_{\text{Voronoi}}(i)$ = volumen de la región más cercana al átomo i

Interpretación: Indica espacio local disponible. Alto volumen puede indicar proximidad a vacancia. Bajo volumen indica compresión local.

20. Energía Cinética

ke (agregados)

Descripción: Energía cinética por átomo.

Ecuación:

$KE_i = (1/2) m v_i^2$

Interpretación: Relacionada con temperatura local. Alta KE indica mayor actividad térmica o movimiento atómico.

21. Features Globales del Sistema

vacancies

Descripción: Número total de vacancias en el sistema (VARIABLE OBJETIVO).

Ecuación:

$N_{\text{vac}} = N_{\text{total_esperado}} - N_{\text{actual}}$

$N_{\text{total_esperado}} = 16384$ (constante del sistema)

N_{actual} = número de átomos presentes

Interpretación: Variable que se busca predecir. Representa defectos puntuales tipo vacancia.

n_atoms_surface

Descripción: Número de átomos en la superficie (después del procesamiento OVITO).

Ecuación:

N_surf = |{átomos seleccionados por ConstructSurfaceModifier}|

Interpretación: Cuantifica átomos expuestos. Mayor superficie puede correlacionar con más vacancias.

22. Metadata

file

Descripción: Nombre del archivo de entrada original.

Tipo: String

file_processed

Descripción: Nombre del archivo procesado por OVITO.

Tipo: String

Resumen Estadístico de Features

Distribución por Categoría

Categoría	Número de Features	Tipo
Mean Shift Clustering	~15	Espacial/Clustering
Momentos de Inercia	~11	Geométrico
Distribución Radial	~26	Espacial/Estadístico
Conectividad	~6	Topológico
Curvatura	~4	Geométrico
Topología	~5	Energético/Geométrico
Capas	~6	Espacial
Entropía Espacial	~4	Estadístico
Convex Hull	~8	Geométrico
Bounding Box	~7	Geométrico
Centroide/Radio	~4	Geométrico
Ratios Derivados	~3	Geométrico
Agregados Atómicos	~11 × 10 propiedades	Físico
Histogramas	~17	Estadístico
Indicadores de Defectos	~8	Físico
TOTAL	~300+	Mixto

Notas Metodológicas

1. Preprocesamiento con OVITO

Todos los análisis se realizan sobre átomos de superficie identificados mediante:

```
ConstructSurfaceModifier(radius=2, smoothing_level=12)
```

2. Cálculo de Vacancias

Las vacancias se calculan sobre la muestra COMPLETA (antes de filtrar superficie):

```
vacancies = 16384 - N_átomos_totales
```

3. Manejo de Valores Faltantes

- Features con NaN se imputan con mediana durante entrenamiento
- Se aplica StandardScaler para normalización

4. Features Prohibidas (Evitar Data Leakage)

Las siguientes features NO se usan en el modelo para evitar fuga de información:

- `n_atoms`
 - `vacancy_fraction`
 - `vacancy_count`
 - `atm_total_ref`
 - `n_atoms_surface` (correlación directa con vacancias)
-

Referencias de Ecuaciones

Convex Hull

- Algoritmo: QuickHull (Barber et al., 1996)
- Software: SciPy `spatial.ConvexHull`

Mean Shift

- Algoritmo: Comaniciu & Meer (2002)
- Software: scikit-learn `MeanShift`

Momentos de Inercia

- Definición clásica de mecánica rígida
- Tensor simétrico 3×3

Dimensión Fractal

- Método: Box-counting
- Referencia: Mandelbrot (1982)

Estrés de von Mises

- Criterio de fluencia: von Mises (1913)
 - Aplicable a materiales dúctiles
-

Interpretación Física General

Relación con Vacancias

Las features capturan múltiples aspectos que pueden correlacionar con número de vacancias:

1. **Geométricas:** Vacancias reducen densidad → mayor volumen hull, menor compacidad
2. **Energéticas:** Vacancias aumentan energía de átomos vecinos → mayor dispersión de pe
3. **Mecánicas:** Vacancias inducen estrés local → mayor stress_vm cerca de defectos
4. **Topológicas:** Vacancias fragmentan estructura → más clusters, menor conectividad
5. **Estructurales:** Vacancias reducen coordinación → mayor frac_coord_le_11

El modelo de Machine Learning (Random Forest) aprende automáticamente las combinaciones no lineales de estas features que mejor predicen el número de vacancias.

Uso en Pipeline ML

Feature Engineering

```
python

X = dataset.drop(['vacancies', 'file', 'n_atoms_surface'])
y = dataset['vacancies']
```

Preprocesamiento

```
python

Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler()),
    ('model', RandomForestRegressor())
])
```

Validación

- Cross-validation: 5-fold
 - Métricas: MAE, RMSE, R^2
 - Train/test split: 80/20
-

Versión del documento: 1.0

Fecha: 2025

Autor: Pipeline ML Nanoestructuras

Framework: Python + OVITO + scikit-learn + SciPy